

基于原型网络的小样本图像分类系统设计与实现

人工智能课程期中项目

2026 年 6 月 17 日

摘要

小样本学习 (Few-Shot Learning) 旨在解决训练样本数量极少情况下的分类问题。传统深度学习模型通常依赖大量标注数据, 而小样本学习希望利用少量样本实现快速泛化。

本实验基于 CUB-200-2011 鸟类数据集实现了原型网络 (Prototypical Network), 构建 Episodic Training Pipeline, 并完成了 1-shot、5-shot 和 10-shot 分类实验。同时实现 Mixup 数据增强策略以及 Fine-tuning 微调方法作为对比基线, 并利用 t-SNE 对特征空间进行可视化分析。

实验结果表明, 随着 Shot 数量增加, 原型网络分类性能显著提升; 基于度量学习的方法在小样本场景下优于传统 Fine-tuning 方法。

1 实验背景

Few-Shot Learning 是当前计算机视觉的重要研究方向。

在 N-way K-shot 分类任务中:

- N 表示类别数
- K 表示每类支持样本数本实验采用:
- 5-way
- 1-shot
- 5-shot
- 10-shot

任务目标是在极少样本条件下完成鸟类细粒度分类。

2 数据集

实验采用 CUB-200-2011 数据集。

数据集包含：

- 200 个鸟类类别
- 11788 张图像
- 细粒度分类任务

图像统一缩放为：

84×84 输入格式

为 RGB 三通道图像。

3 方法设计

3.1 原型网络

原型网络属于基于度量学习（Metric-Based Learning）的方法。

对于支持集：

$$S = \{(x_i, y_i)\}$$

首先利用 ResNet18 提取特征：

$$z_i = f_{\theta}(x_i)$$

随后计算类别原型：

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_{\theta}(x_i)$$

其中：

$$c_k$$

表示第 k 类原型向量。

对于 Query 样本：

$$X_q$$

计算欧氏距离：

$$d(z_q, c_k) = \|z_q - c_k\|^2$$

最终分类概率：

$$p(y = k|x_q) = \frac{\exp(-d(z_q, c_k))}{\sum_j \exp(-d(z_q, c_j))}$$

3.2 Episodic Training

每轮训练随机构造一个 Episode：

- 5 个类别
- 每类 K 个 Support 样本
- 每类 10 个 Query 样本训练过程模拟真实 Few-Shot

场景。

3.3 Mixup 数据增强

Mixup 生成新样本：

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j$$

标签同步混合：

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j$$

其中：

$$\lambda \sim \text{Beta}(\alpha, \alpha)$$

3.4 Fine-Tuning 基线

采用 ResNet18 预训练模型。仅使用少量样本重新训练分类层：

$$\hat{y} = g(f(x))$$

用于与原型网络进行性能比较。

4 实验设置

硬件环境：

- CPU: Intel Core i9-13900H
- RAM: 16GB
- GPU: 无软件环境：
- Python 3.9
- PyTorch 2.8
- Torchvision 0.23

优化器：

Adam

学习率：

$$10^{-3}$$

训练 Episode：

150

5 实验中的问题分析

第一次实验：未进行 finetune 方式训练，未完成核心目标，

第二次实验:

Method	1-shot	5-shot	10-shot
baseline	0.416	0.657	0.754
mixup	0.347	0.436	0.511
cutmix	0.467	0.710	0.779
finetune	0.437	0.437	0.437

Mixup 下降原因:

Mixup 虽然在传统监督学习中具有较好的泛化能力,但在 Prototypical Network 中,由于其改变了样本的类别中心分布,导致 Prototype 估计偏移,因此分类性能下降。

Finetune 保持不变原因:

旧代码为:

```
finetune_acc = train_finetune(x, y)
```

```
results["finetune"]={  
    "1": finetune_acc,  
    "5": finetune_acc,  
    "10": finetune_acc  
}
```

本质上只训练了一次,所以实际上:

Shot Accuracy

1 0.437

5 0.437

10 0.437

是假数据,因为根本没区分 shot。

第三次实验:

Method	1-shot	5-shot	10-shot
baseline	0.387	0.633	0.781
mixup	0.336	0.435	0.520
cutmix	0.454	0.690	0.779
finetune	0.208	0.205	0.212

Baseline 正常：因为支持样本越多，Prototype 更稳定，类中心更准确，Query 更容易分类 所以准确率上升。

Mixup 下降：因为 Few-Shot 本来数据就少。

Mixup:

$$x' = \lambda x_i + (1 - \lambda)x_j$$

会把两只不同鸟混在一起。

CutMix 更好的原因：CutMix 不是整张图混合，而是把局部区域替换。

Finetune 只有 20%且 1-shot、5-shot、10-shot 无明显变化原因：在极少样本条件下，Fine-tuning 方法需要学习大量分类参数，而 ProtoNet 通过度量学习直接构建类别原型，因此对样本数量依赖更小。

实验结果表明：ProtoNet 在 10-shot 条件下达到 78.1% 准确率，而 Fine-tuning 方法仅达到约 21.2%。说明度量学习方法更适合小样本图像分类任务。

第四次实验：

Method	1-shot	5-shot	10-shot
baseline	0.434	0.667	0.760
mixup	0.329	0.452	0.519
cutmix	0.441	0.686	0.766
finetune	0.385	0.421	0.452

对 fine-tuning.py 代码 `dataset = TensorDataset(x, y)` 进行修改，使训练集规模大幅缩小，模型反而更容易记住这些样本。

6 最终实验结果

6.1 不同 Shot 数量实验

Method	1-shot	5-shot	10-shot
baseline	0.434	0.667	0.760
mixup	0.329	0.452	0.519
cutmix	0.441	0.686	0.766
finetune	0.385	0.421	0.452

6.2 结果分析

可以观察到：

1. ProtoNet 在所有 Shot 设置下均优于 Fine-tuning。
2. Shot 数量增加后准确率明显提升。
3. 10-shot 达到最高准确率 75.37%。
4. Mixup 在本实验中效果下降，原因是 Mixup 在 Few-Shot 场景下可能破坏类别边界。

6.3 度量学习与微调方法比较

ProtoNet：

- 不依赖大量样本
- 泛化能力强
- 更适合 Few-Shot

Fine-Tuning：

- 容易过拟合
- 对训练样本敏感

- 需要更多数据


7 可视化分析


1) 实验生成:

- Loss Curve
- t-SNE 特征分布图
- Comparison Table
- Confusion Matrix

t-SNE 结果表明类别特征具有良好聚类性。

2) 可视化结果:





8 结论

本文实现了完整 Few-Shot 学习系统。

实验表明：

- ProtoNet 性能最佳
- Few-shot 下 Fine-tuning 较弱
- Shot 增加显著提升性能

9 成员分工

林瑞荷：配置环境

刘思雅：数据处理与实验设计

唐明江：原型网络实现

包涵：数据增强与可视化

朱家欣：报告撰写与结果分析